Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ **ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ**

КАФЕДРА **КОМПЬЮТЕРНЫЕ СИСТЕМЫ И СЕТИ (ИУ6)**

НАПРАВЛЕНИЕ ПОДГОТОВКИ **09.04.01 Информатика и вычислительная техника**

МАГИСТЕРСКАЯ ПРОГРАММА **09.04.01/07 Интеллектуальные системы анализа, обработки и интерпретации больших данных**

О Т Ч Е Т

по домашнему заданию № 1

Название: Дескриптивный анализ данных

Дисциплина: Методы машинного обучения

Студент ИУ6-22М _____ Т.И. Кадыров
(Группа) (Подпись, дата) (И.О. Фамилия)

Преподаватель _____ С.Ю. Папулин
(Подпись, дата) (И.О. Фамилия)

Москва, 2024

Домашнее задание №1. Дескриптивный анализ данных

Кадыров Т.И. ИУ6-22М

Цель работы

Приобрести опыт решения практических задач по анализу данных, таких как загрузка, трансформация, вычисление простых статистик и визуализация данных в виде графиков и диаграмм, посредством языка программирования Python.

Рассчет варианта

In [ ]:
```
surname = "Кадыров"  # Ваша фамилия

alp = 'абвгдеёжзийклмнопрстуфхцчшщъыьэюя'
w = [1, 42, 21, 21, 34,  6, 44, 26, 18, 44, 38, 26, 14, 43,  4, 49, 45,
        7, 42, 29,  4,  9, 36, 34, 31, 29,  5, 30,  4, 19, 28, 25, 33]

d = dict(zip(alp, w))
variant =  sum([d[el] for el in surname.lower()]) % 40 + 1

print("Задача № 1, шаг 5 - вариант: ", variant % 5 + 1)
print("Задача № 1, шаг 11 - вариант: ", variant % 2 + 1 )
print("задача № 2 - вариант: ", variant % 4 + 1)
```

```
Задача № 1, шаг 5 - вариант:  4
Задача № 1, шаг 11 - вариант:  2
задача № 2 - вариант:  4
```

Задание 1. Анализ индикаторов качества государственного управления (The Worldwide Government Indicators, WGI)

1.1 Загрузите данные в DataFrame

In [ ]:
```
import pandas as pd
```

In [ ]:
```
# Загружаем data frame, используем двойной заголовок, чтобы сохранить года
df = pd.read_excel('./data/wgidataset.xlsx', sheet_name='ControlofCorruption', header=[13,14])
df.head()
```

Out[ ]:

	Unnamed: 0_level_0	Unnamed: 1_level_0						1996		1998	...	
	Country/Territory	Code	Estimate	StdErr	NumSrc	Rank	Lower	Upper	Estimate	StdErr	...	NumSrc
0	Aruba	ABW	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	2.0
1	Andorra	ADO	1.318143	0.480889	1.0	87.096771	72.043015	96.774193	1.334759	0.453149	...	1.0
2	Afghanistan	AFG	-1.291705	0.340507	2.0	4.301075	0.000000	27.419355	-1.176012	0.324013	...	8.0
3	Angola	AGO	-1.167702	0.262077	4.0	9.677420	0.537634	27.419355	-1.180451	0.227055	...	10.0
4	Anguilla	AIA	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	1.0

5 rows × 146 columns

In [ ]:
```
# Объединяем год и название столбца и приводим все к одинарному заголовку
new_columns = [col[1] if col[1] in ['Country/Territory', 'Code'] else f"{col[0]}.{col[1]}" for col in df.columns
df.columns = new_columns
df.head()
```

Out[ ]:

	Country/Territory	Code	1996.Estimate	1996.StdErr	1996.NumSrc	1996.Rank	1996.Lower	1996.Upper	1998.Estimate	1998.StdE
0	Aruba	ABW	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na
1	Andorra	ADO	1.318143	0.480889	1.0	87.096771	72.043015	96.774193	1.334759	0.4531
2	Afghanistan	AFG	-1.291705	0.340507	2.0	4.301075	0.000000	27.419355	-1.176012	0.3240
3	Angola	AGO	-1.167702	0.262077	4.0	9.677420	0.537634	27.419355	-1.180451	0.2270
4	Anguilla	AIA	NaN	NaN	NaN	NaN	NaN	NaN	NaN	Na

5 rows × 146 columns

1.2 Отсортируйте данные по убыванию индекса DataFrame

In [ ]:
```
df_desc = df.iloc[::-1]
df_desc.head()
```

Out[ ]:

	Country/Territory	Code	1996.Estimate	1996.StdErr	1996.NumSrc	1996.Rank	1996.Lower	1996.Upper	1998.Estimate	1998.St
213	Zimbabwe	ZWE	-0.278847	0.244907	5.0	47.849461	30.645161	60.752689	-0.504802	0.19
212	Zambia	ZMB	-0.840641	0.262077	4.0	24.731182	5.913979	41.397850	-0.853156	0.22
211	Congo, Dem. Rep.	ZAR	-1.647852	0.315914	3.0	0.000000	0.000000	12.365591	-1.416679	0.31
210	South Africa	ZAF	0.732927	0.210325	6.0	76.344086	66.129036	81.182793	0.638809	0.18
209	Serbia	SRB	-1.140072	0.262077	4.0	11.827957	0.537634	29.032259	-1.195605	0.19

5 rows × 146 columns

1.3 Отобразите данные по индексу WGI за 2022 год в виде горизонтального столбчатого графика

In [ ]:
```
import matplotlib.pyplot as plt
```

In [ ]:
```
# Сортируем по полю 2022.Rank
df_sort = df.sort_values(by='2022.Rank')
# Удаляем те строки, у которых за этот год нет данных
df_sort_dropna = df_sort.dropna(subset=['2022.Rank'])
plt.figure(figsize=(30,60))
plt.barh(df_sort_dropna['Country/Territory'], df_sort_dropna['2022.Rank'])
plt.xlabel('Rank')
plt.ylabel('Country')
plt.title('Страны по индексу WGI за 2022 год')
plt.show()
```

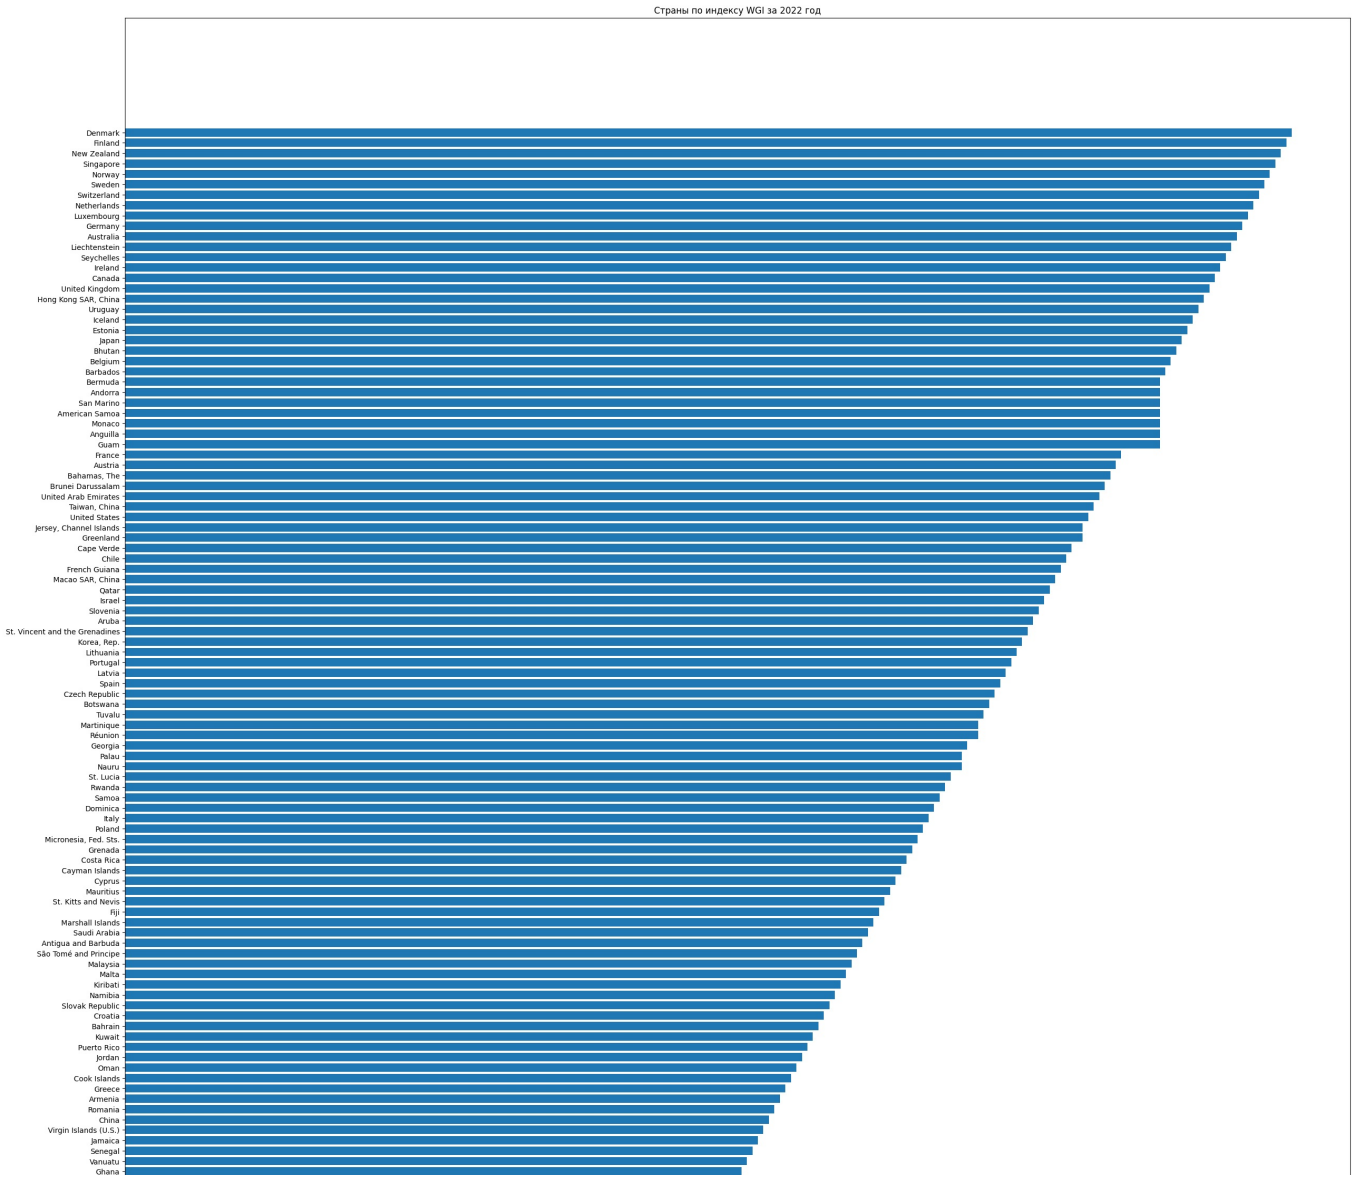

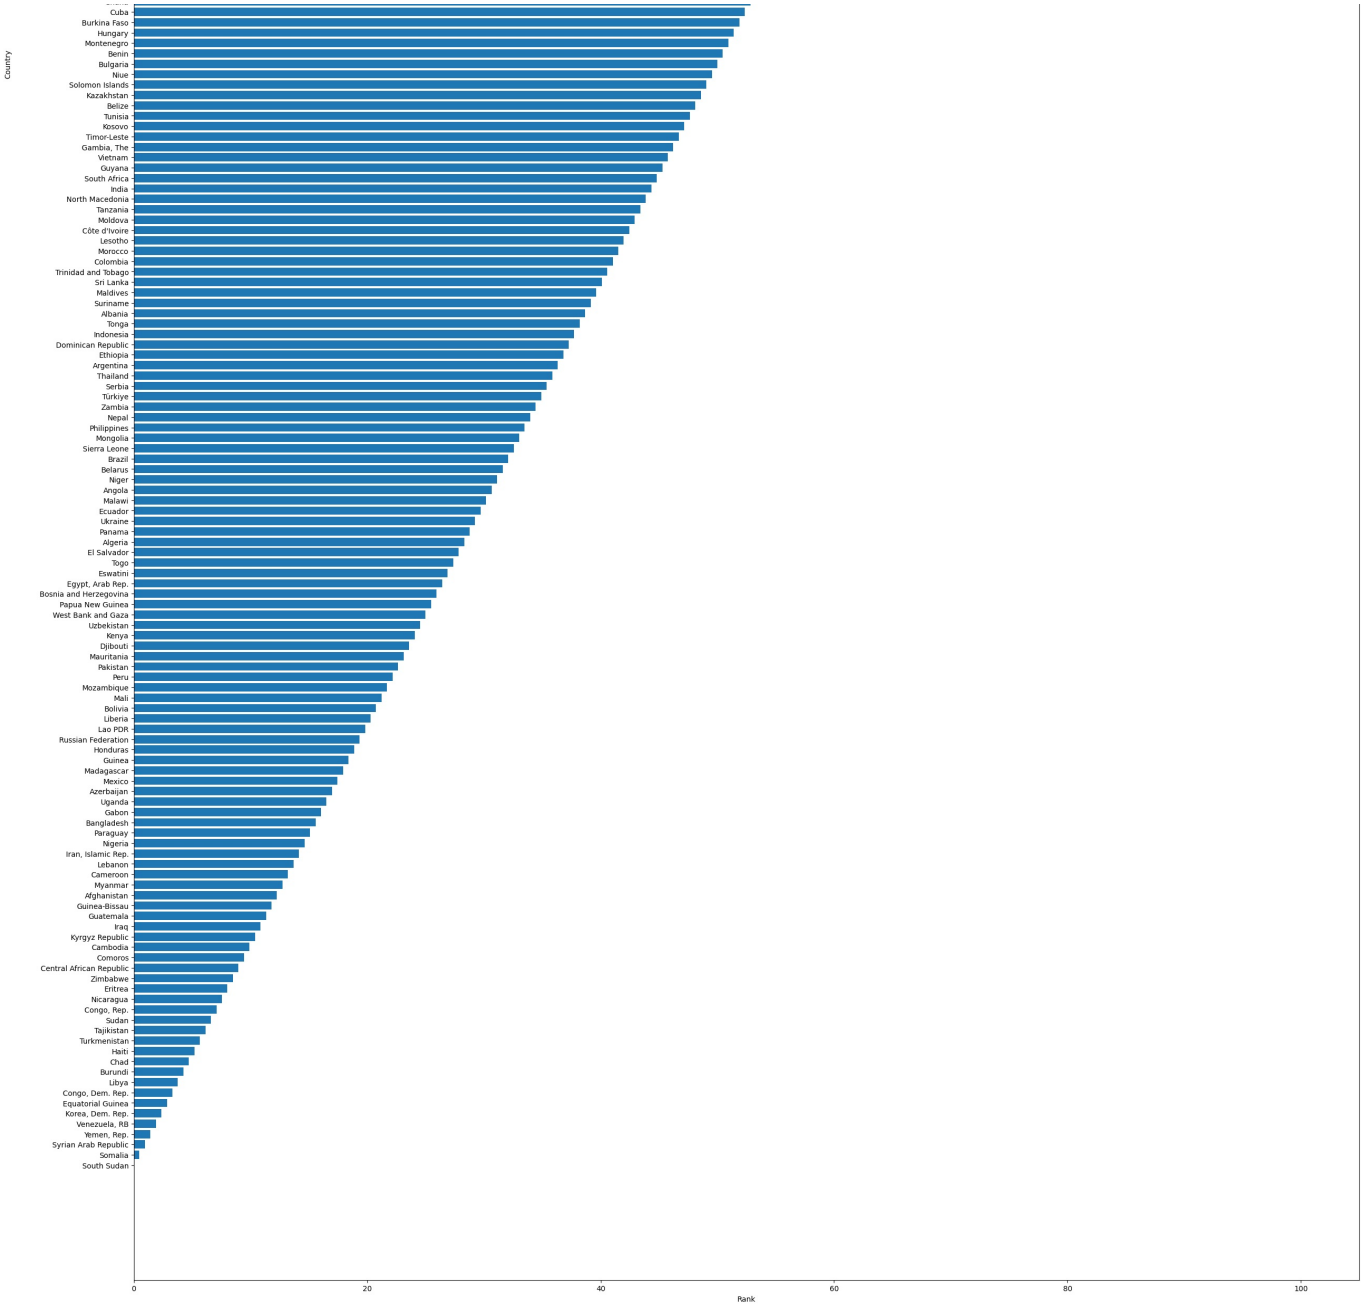

1.4 Сформируйте DataFrame из исходного для региона в соответствии с Вашим вариантом

Вариант 4. Middle East and North Africa (MENA)

In [ ]:
```
# Исходный датасет
df_region = pd.read_excel('./data/regions.xlsx')
# Страны региона MENA
df_mena = df_region[df_region['Region'] == 'MENA']
# WGI индексы для стран MENA
df_wgi_mena = df.merge(df_mena, how='inner', left_on='Code', right_on='Code')
# Удаляем столбец Country/Territory. Выставляем индекс по Country
df_wgi_mena.set_index('Country', inplace=True)
df_wgi_mena.drop(columns='Country/Territory', inplace=True)
```

1.5 Выведите данные DataFrame'a

In [ ]:
```
df_wgi_mena
```

Out[ ]:

Country	Code	1996.Estimate	1996.StdErr	1996.NumSrc	1996.Rank	1996.Lower	1996.Upper	1998.Estimate	1998.StdErr	1998.Nu
United Arab Emirates	ARE	-0.005579	0.312212	3.0	57.526882	35.483871	72.043015	0.033033	0.260451	
Bahrain	BHR	0.328689	0.312212	3.0	63.978493	50.537636	77.419357	0.250789	0.260451	
Algeria	DZA	-0.566741	0.262077	4.0	33.333332	16.666666	52.688171	-0.916649	0.227055	
Egypt	EGY	-0.472254	0.244907	5.0	38.709679	19.892473	53.763439	-0.477870	0.198134	
Iran	IRN	-0.480607	0.262077	4.0	37.634407	18.817204	54.301075	-0.460588	0.227055	
Iraq	IRQ	-1.602183	0.262077	4.0	0.537634	0.000000	9.139785	-1.422613	0.227055	
Israel	ISR	1.354008	0.210325	6.0	88.172043	81.182793	91.397850	1.148573	0.188628	
Jordan	JOR	-0.035407	0.244907	5.0	55.376343	39.784946	65.053764	0.112762	0.198134	
Kuwait	KWT	0.478682	0.262077	4.0	70.430107	59.139786	80.645164	0.562503	0.227055	
Lebanon	LBN	-0.659695	0.262077	4.0	31.182796	13.978495	49.462364	-0.474878	0.227055	
Libya	LBY	-0.871937	0.262077	4.0	20.430107	3.763441	39.247311	-0.907353	0.227055	
Morocco	MAR	-0.106927	0.262077	4.0	53.225807	34.946236	63.440861	0.103346	0.227055	
Oman	OMN	0.414642	0.262077	4.0	67.741936	56.989246	77.419357	0.724727	0.227055	
Qatar	QAT	-0.045596	0.262077	4.0	54.838711	37.634407	66.129036	0.474643	0.227055	
Saudi Arabia	SAU	-0.163303	0.262077	4.0	51.075268	32.258064	62.903225	-0.263509	0.227055	
Syria	SYR	-0.881176	0.262077	4.0	19.892473	3.763441	38.709679	-0.914690	0.227055	
Tunisia	TUN	-0.533678	0.262077	4.0	35.483871	17.741936	53.225807	-0.433108	0.227055	
Yemen	YEM	-0.743732	0.262077	4.0	27.419355	8.602151	47.311829	-0.998175	0.227055	

18 rows × 146 columns

1.6 Постройте графики индекса WGI за 1996-2022 для стран своего региона (estimate)

In [ ]:
```
# Оставляем только столбцы Estimate и Country
df_plot_mena = df_wgi_mena.filter(regex='Estimate|Country')
# Транспонируем датафрейм и отрисовываем график на каждую страну
df_plot_mena.T.plot(figsize=(35,15), grid=True, marker='o', title='WGI 1996-2022')
```

Out[ ]:
```
<Axes: title={'center': 'WGI 1996-2022'}>
```

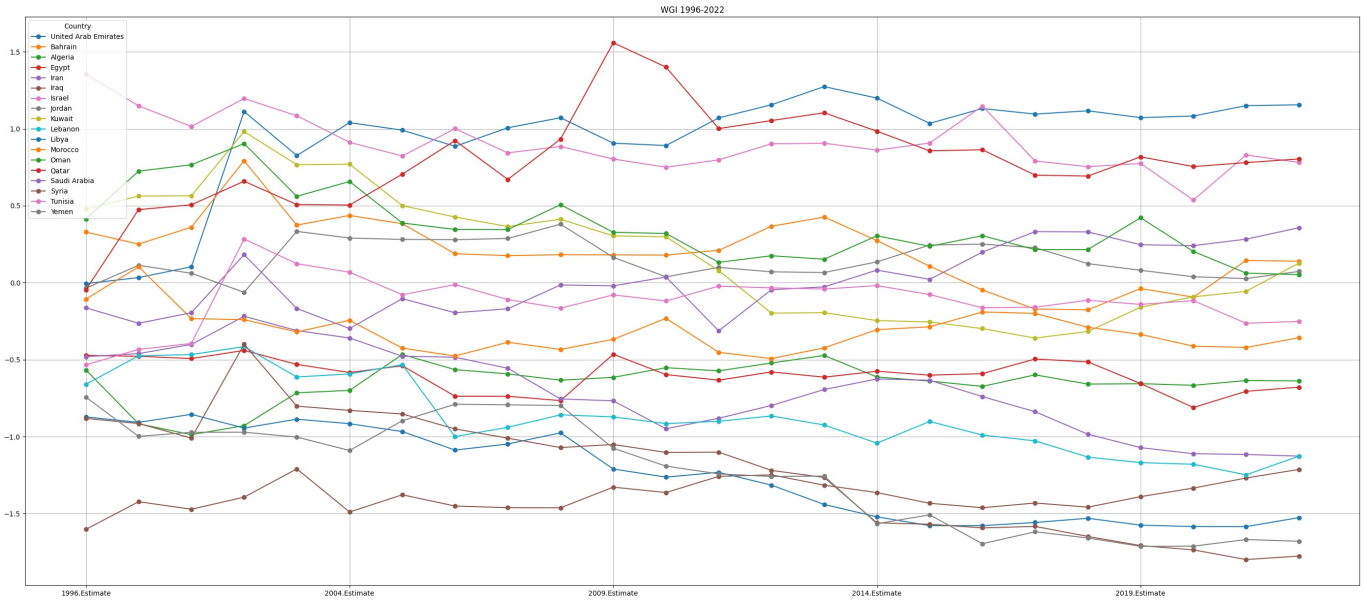

1.7 Найдите страны с наибольшим и наименьшим значением WGI Вашего варианта региона за 2022 год

In [ ]:
```
# Страна с минимальным значением
minWgi = df_wgi_mena['2022.Estimate'].idxmin()
minWgi
```

Out[ ]:
```
'Syria'
```

In [ ]:
```
# Страна с максимальным значением
maxWgi = df_wgi_mena['2022.Estimate'].idxmax()
maxWgi
```

Out[ ]:
```
'United Arab Emirates'
```

1.8 Определите средние значения региона за каждый год в период с 1996 по 2022

In [ ]:
```
# Оставляем только столбцы Estimate
df_wgi_mena_estimate = df_wgi_mena.filter(regex='Estimate')
# Считаем среднее по региону за каждый год
mean = df_wgi_mena_estimate.mean()
mean.name="mean"
mean
```

Out[ ]:
```
1996.Estimate   -0.255155
1998.Estimate   -0.214392
2000.Estimate   -0.227920
2002.Estimate    0.005365
2003.Estimate   -0.110138
2004.Estimate   -0.134619
2005.Estimate   -0.146972
2006.Estimate   -0.205434
2007.Estimate   -0.228394
2008.Estimate   -0.197921
2009.Estimate   -0.200338
2010.Estimate   -0.242790
2011.Estimate   -0.289805
2012.Estimate   -0.269579
2013.Estimate   -0.263348
2014.Estimate   -0.310855
2015.Estimate   -0.337412
2016.Estimate   -0.340242
2017.Estimate   -0.371198
2018.Estimate   -0.402726
2019.Estimate   -0.399918
2020.Estimate   -0.443916
2021.Estimate   -0.416095
2022.Estimate   -0.382464
Name: mean, dtype: float64
```

1.9 Постройте графики индекса WGI за 1996-2022 для стран своего региона и выделите страны с наибольшим и наименьшим значением WGI за 2022 год, а также отобразите среднее значение по региону и РФ.

In [ ]:
```
# Графики по всем странам
ax = df_plot_mena.T.plot(figsize=(35,15), grid=True, marker='o', title='WGI 1996-2022', color='grey', legend=Fa
# Графики по странам с наибольшим и наименьшим значениями за 2022 год
df_plot_mena.loc[maxWgi].plot(color='green', marker = 'o', legend=True, ax = ax)
df_plot_mena.loc[minWgi].plot(color='red', marker = 'o', legend=True, ax = ax)
# График по среднему значению
mean.plot(title='mean', marker = 'o', color='blue', legend=True, ax = ax)
# Данные по России
df_wgi_russia = df[df['Code'] == 'RUS']
df_wgi_russia.set_index('Country/Territory', inplace=True)
df_wgi_russia = df_wgi_russia.filter(regex='Estimate')
# График по России
df_wgi_russia.T.plot(color='orange', marker = 'o', legend=True, ax = ax)
```

Out[ ]:
```
<Axes: title={'center': 'mean'}>
```

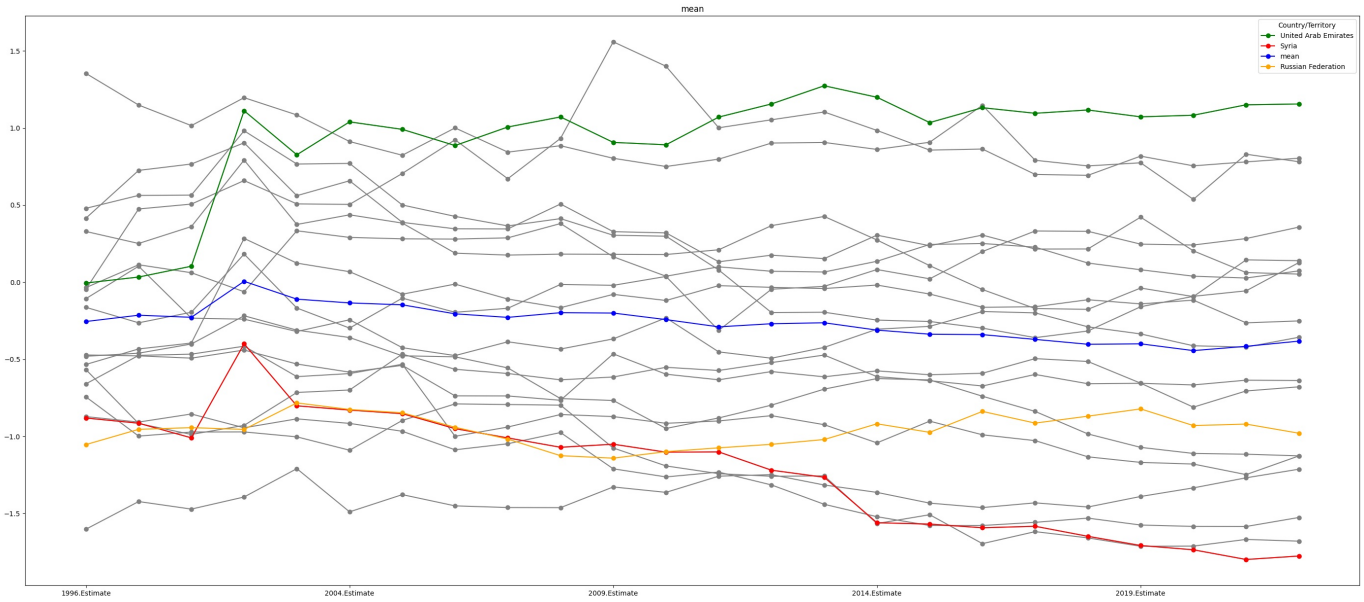

1.11 Определите, как изменилось значение показателя rank с 1996 по 2022

Вариант 2. Americas

In [ ]:
```
# Страны региона AME
df_ame = df_region[df_region['Region'] == 'AME']
# WGI индексы для стран MENA
df_wgi_ame = df.merge(df_ame, how='inner', left_on='Code', right_on='Code')
# Создаем индекс, оставляем только поля Rank за 1996 и 2022
df_wgi_ame.set_index('Country', inplace=True)
df_wgi_ame = df_wgi_ame.filter(regex='1996.Rank|2022.Rank')
# Данные Rank по России
df_wgi_russia = df[df['Code'] == 'RUS']
df_wgi_russia.set_index('Country/Territory', inplace=True)
df_wgi_russia.rename_axis('Country', inplace=True)
df_wgi_russia = df_wgi_russia.filter(regex='1996.Rank|2022.Rank')
# Объединяем два датафрейма
df_wgi_ame_rus = pd.concat([df_wgi_ame, df_wgi_russia])
# Вывод промежуточного результата
df_wgi_ame_rus
```

Out[ ]:

Country	1996.Rank	2022.Rank
Argentina	53.763439	36.320755
Bahamas	83.870964	84.433960
Bolivia	25.268818	20.754717
Brazil	56.989246	32.075470
Barbados	90.860214	89.150940
Canada	96.236557	93.396225
Chile	90.322578	80.660378
Colombia	36.559139	41.037735
Costa Rica	75.268814	66.981133
Cuba	63.440861	52.358490
Dominica	80.107529	69.339622
Dominican Republic	41.397850	37.264153
Ecuador	30.107527	29.716982
Grenada	80.107529	67.452827
Guatemala	23.655914	11.320755
Guyana	52.688171	45.283020
Honduras	14.516129	18.867924
Haiti	9.139785	5.188679
Jamaica	61.827957	54.245281
Saint Lucia	NaN	70.754715
Mexico	36.021507	17.452829
Nicaragua	33.870968	7.547170
Panama	50.537636	28.773584
Peru	41.935482	22.169811
Paraguay	10.215054	15.094339
El Salvador	21.505377	27.830189
Suriname	61.290321	39.150944
Trinidad and Tobago	80.645164	40.566036
Uruguay	82.258064	91.981133
United States of America	91.397850	82.547173
Saint Vincent and the Grenadines	NaN	77.358490
Venezuela	22.580645	1.886792
Russian Federation	15.053763	19.339622

In [ ]:
```
# Вычисляем изменение 2022 года относительного 1996
df_changes = df_wgi_ame_rus.pct_change(axis=1)
# Умножаем на 100 для получения процентов и добавляем к исходным данным
df_wgi_changes = df_wgi_ame_rus.copy()
df_wgi_changes['Change procent'] = (df_changes['2022.Rank'] * 100).round(2)
df_wgi_changes
```

```
/tmp/ipykernel_41439/4014822730.py:2: FutureWarning: The default fill_method='pad' in DataFrame.pct_change is de
precated and will be removed in a future version. Call ffill before calling pct_change to retain current behavio
r and silence this warning.
  df_changes = df_wgi_ame_rus.pct_change(axis=1)
```

Out[ ]:

Country	1996.Rank	2022.Rank	Change procent
Argentina	53.763439	36.320755	-32.44
Bahamas	83.870964	84.433960	0.67
Bolivia	25.268818	20.754717	-17.86
Brazil	56.989246	32.075470	-43.72
Barbados	90.860214	89.150940	-1.88
Canada	96.236557	93.396225	-2.95
Chile	90.322578	80.660378	-10.70
Colombia	36.559139	41.037735	12.25
Costa Rica	75.268814	66.981133	-11.01
Cuba	63.440861	52.358490	-17.47
Dominica	80.107529	69.339622	-13.44
Dominican Republic	41.397850	37.264153	-9.99
Ecuador	30.107527	29.716982	-1.30
Grenada	80.107529	67.452827	-15.80
Guatemala	23.655914	11.320755	-52.14
Guyana	52.688171	45.283020	-14.05
Honduras	14.516129	18.867924	29.98
Haiti	9.139785	5.188679	-43.23
Jamaica	61.827957	54.245281	-12.26
Saint Lucia	NaN	70.754715	NaN
Mexico	36.021507	17.452829	-51.55
Nicaragua	33.870968	7.547170	-77.72
Panama	50.537636	28.773584	-43.07
Peru	41.935482	22.169811	-47.13
Paraguay	10.215054	15.094339	47.77
El Salvador	21.505377	27.830189	29.41
Suriname	61.290321	39.150944	-36.12
Trinidad and Tobago	80.645164	40.566036	-49.70
Uruguay	82.258064	91.981133	11.82
United States of America	91.397850	82.547173	-9.68
Saint Vincent and the Grenadines	NaN	77.358490	NaN
Venezuela	22.580645	1.886792	-91.64
Russian Federation	15.053763	19.339622	28.47

1.12 Выведите таблицу для Вашего варианта (WGI - rank)

In [ ]:
```
# Создаем новый датафрейм для заполнения
rows = ['mean_2022', 'max_2022', 'min_2022', 'Russia_2022'] # Список строк для нового датафрейма
cols = ['Регион', 'Страна', 'WGI 1996', 'WGI 2022', 'Изменение'] # Список столбцов для нового датафрейма
table = pd.DataFrame(index=rows,columns=cols)
# Заполняем первый столбец (Регион)
table.loc['mean_2022', 'Регион'] = "AME"
table.loc['max_2022', 'Регион'] = "AME"
table.loc['min_2022', 'Регион'] = "AME"
table.loc['Russia_2022', 'Регион'] = "ECA"
# Заполняем второй столбец (Страна)
minAmeIdx = df_wgi_ame['2022.Rank'].idxmin()
maxAmeIdx = df_wgi_ame['2022.Rank'].idxmax()
rusIdx = 'Russian Federation'
table.loc['mean_2022', 'Страна'] = "-"
table.loc['max_2022', 'Страна'] = maxAmeIdx
table.loc['min_2022', 'Страна'] = minAmeIdx
table.loc['Russia_2022', 'Страна'] = rusIdx
# Заполняем третий столбец (WGI 1996)
table.loc['mean_2022', 'WGI 1996'] = df_wgi_ame['1996.Rank'].mean()
table.loc['max_2022', 'WGI 1996'] = df_wgi_ame.loc[maxAmeIdx, '1996.Rank']
table.loc['min_2022', 'WGI 1996'] = df_wgi_ame.loc[minAmeIdx, '1996.Rank']
```

```
table.loc['Russia_2022', 'WGI 1996'] = df_wgi_ame_rus.loc[rusIdx, '1996.Rank']
# Заполняем четвертый столбец (WGI 2022)
table.loc['mean_2022', 'WGI 2022'] = df_wgi_ame['2022.Rank'].mean()
table.loc['max_2022', 'WGI 2022'] = df_wgi_ame.loc[maxAmeIdx, '2022.Rank']
table.loc['min_2022', 'WGI 2022'] = df_wgi_ame.loc[minAmeIdx, '2022.Rank']
table.loc['Russia_2022', 'WGI 2022'] = df_wgi_ame_rus.loc[rusIdx, '2022.Rank']
# Заполняем пятый столбец (Изменение)
# Для рассчета среднего изменения по региону из таблицы изменений удаляем Россию
df_wgi_changes_ame = df_wgi_changes.drop(rusIdx)
table.loc['mean_2022', 'Изменение'] = df_wgi_changes_ame['Change procent'].mean().round(2)
table.loc['max_2022', 'Изменение'] = df_wgi_changes_ame.loc[maxAmeIdx, 'Change procent']
table.loc['min_2022', 'Изменение'] = df_wgi_changes_ame.loc[minAmeIdx, 'Change procent']
table.loc['Russia_2022', 'Изменение'] = df_wgi_changes.loc[rusIdx, 'Change procent']
table
```

Out[ ]:

	Регион	Страна	WGI 1996	WGI 2022	Изменение
mean_2022	AME	-	53.27957	45.59257	-19.16
max_2022	AME	Canada	96.236557	93.396225	-2.95
min_2022	AME	Venezuela	22.580645	1.886792	-91.64
Russia_2022	ECA	Russian Federation	15.053763	19.339622	28.47

1.13 Отобразите диаграмму размаха индекса WGI за 2022 для всех стран и для каждого региона в отдельности (на одном графике)

In [ ]:
```
# Создаем датафрейм со всеми странами и объединяем с датафреймом с названием региона
df_merged = df.merge(df_region, how='inner', left_on='Code', right_on='Code')
# Оставляем только индекс Country, код региона и WGI за 2022 год
df_merged = df_merged.filter(regex='^Country$|2022.Estimate|Region')
df_merged.set_index('Country', inplace=True)
# Данные по каждому региону. Переименовываем столбец Estimate для отображения на общем графике
df_boxplot_ame = df_merged[df_merged['Region'] == 'AME'].rename(columns={'2022.Estimate':'AME'})
df_boxplot_eca = df_merged[df_merged['Region'] == 'ECA'].rename(columns={'2022.Estimate':'ECA'})
df_boxplot_ssa = df_merged[df_merged['Region'] == 'SSA'].rename(columns={'2022.Estimate':'SSA'})
df_boxplot_eu = df_merged[df_merged['Region'] == 'WE/EU'].rename(columns={'2022.Estimate':'WE/EU'})
df_boxplot_mena = df_merged[df_merged['Region'] == 'MENA'].rename(columns={'2022.Estimate':'MENA'})
df_boxplot_ap = df_merged[df_merged['Region'] == 'AP'].rename(columns={'2022.Estimate':'AP'})
# Данные по всем странам
df_boxplot_all = df_merged.rename(columns={'2022.Estimate':'All Countries'})
# Объединяем в общий датафрейм
df_boxplot = pd.concat([df_boxplot_ame, df_boxplot_eca, df_boxplot_ssa, df_boxplot_eu, df_boxplot_mena, df_boxp
# Строим график
df_boxplot.boxplot()
```

Out[ ]: <Axes: >

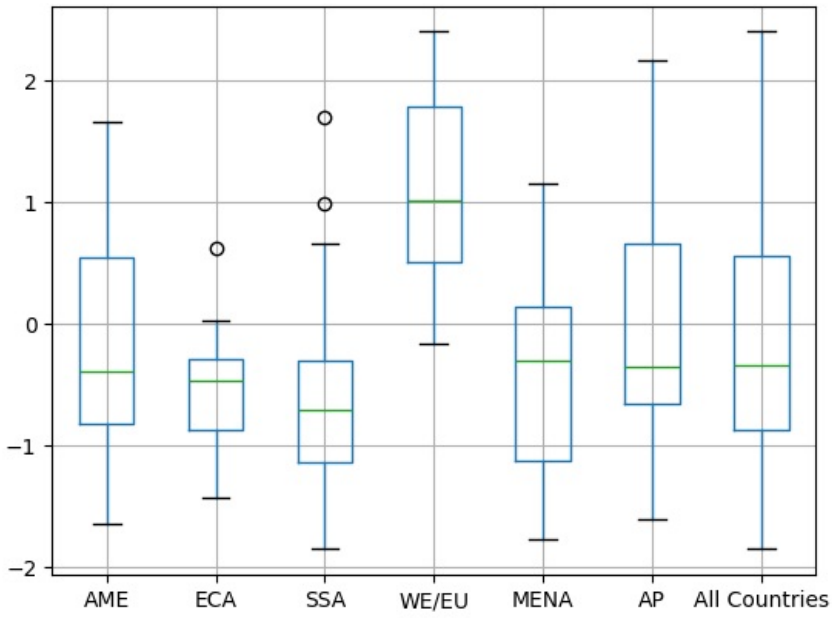

Задание 2. Анализ рынка акций

2.1 Загрузите данные в один dataframe из всех файлов в папке /data/stock. Все файлы имеют одинаковую структуру, в том числе наименование столбцов. В качестве значений индекса dataframe'a необходимо указать значения столбца "Date". Название столбцов должные соответствовать названию акций (имя файла без .csv), а их значения -

значениям цены закрытия (столбец "Close" в файлах .csv)

In [ ]:
```
import glob
import pandas as pd
```

In [ ]:
```
# Получение списка csv
files = glob.glob('./data/stock/*.csv')
# Загрузка данных по каждой компании в один датафрейм
df = pd.DataFrame()
for file in files:
    data = pd.read_csv(file, index_col='Date', usecols=['Date','Close'])
    compName = file.split('/')[-1].split('.')[0]
    df[compName] = data['Close']
df.head()
```

Out[ ]:

Date	TWLO	CSCO	DBX	AMZN	AAPL	SPOT	NVDA	NFLX	SHOP	ABNB	...	
2022-01-01	206.119995	55.669998	24.750000	149.573502	174.779999	196.259995	244.860001	427.140015	NaN	153.970001	...	310.9
2022-02-01	174.800003	55.770000	22.690001	153.563004	165.119995	156.190002	243.850006	394.519989	NaN	151.490005	...	298.7
2022-03-01	164.809998	55.759998	23.250000	162.997498	174.610001	151.020004	272.859985	374.589996	NaN	171.759995	...	308.3
2022-04-01	111.820000	48.980000	21.750000	124.281502	157.649994	101.650002	185.470001	190.360001	NaN	153.210007	...	277.5
2022-05-01	105.169998	45.049999	20.840000	120.209503	148.839996	112.769997	186.720001	197.440002	NaN	120.870003	...	271.8

5 rows × 25 columns

2.2 Рассчитайте корреляционную матрицу для всех акций

In [ ]:
```
corr = df.corr()
corr
```

Out[ ]:

	TWLO	CSCO	DBX	AMZN	AAPL	SPOT	NVDA	NFLX	SHOP	ABNB	...	MSFT	
TWLO	1.000000	0.383777	-0.113102	0.314869	0.042914	0.059969	-0.244797	-0.102302	0.657843	0.429915	...	-0.094023	-0
CSCO	0.383777	1.000000	0.496982	0.404820	0.589552	0.424007	0.320159	0.497727	-0.144612	0.594365	...	0.391476	0
DBX	-0.113102	0.496982	1.000000	0.478171	0.740429	0.525305	0.519374	0.635239	0.424923	0.332740	...	0.648164	0
AMZN	0.314869	0.404820	0.478171	1.000000	0.665715	0.875779	0.765294	0.735466	0.824934	0.830690	...	0.838702	0
AAPL	0.042914	0.589552	0.740429	0.665715	1.000000	0.687415	0.633114	0.701937	0.465147	0.617430	...	0.790691	0
SPOT	0.059969	0.424007	0.525305	0.875779	0.687415	1.000000	0.925270	0.920771	0.737909	0.753797	...	0.949380	0
NVDA	-0.244797	0.320159	0.519374	0.765294	0.633114	0.925270	1.000000	0.910910	0.713391	0.649664	...	0.935386	0
NFLX	-0.102302	0.497727	0.635239	0.735466	0.701937	0.920771	0.910910	1.000000	0.852517	0.646901	...	0.900263	0
SHOP	0.657843	-0.144612	0.424923	0.824934	0.465147	0.737909	0.713391	0.852517	1.000000	0.696599	...	0.842193	0
ABNB	0.429915	0.594365	0.332740	0.830690	0.617430	0.753797	0.649664	0.646901	0.696599	1.000000	...	0.679204	0
PINS	-0.141953	0.384233	0.710191	0.666996	0.640294	0.842858	0.815629	0.930638	0.846115	0.554616	...	0.837576	0
HPQ	0.728572	0.214262	-0.177013	0.235247	0.067074	0.005774	-0.160502	-0.203337	0.436406	0.390153	...	-0.034581	-0
XIACY	0.447846	0.474311	0.382992	0.654564	0.408747	0.647331	0.445645	0.505430	0.519367	0.564475	...	0.565831	0
MU	0.315313	0.472688	0.440043	0.906932	0.606787	0.902439	0.796707	0.789551	0.804352	0.842928	...	0.849930	0
META	-0.072886	0.374998	0.552874	0.830910	0.705358	0.973401	0.961389	0.897908	0.735282	0.723419	...	0.966868	0
MSFT	-0.094023	0.391476	0.648164	0.838702	0.790691	0.949380	0.935386	0.900263	0.842193	0.679204	...	1.000000	0
TCOM	-0.562073	0.257188	0.423136	0.309545	0.439363	0.640120	0.787859	0.766681	0.592950	0.294269	...	0.662193	1
ORCL	-0.393536	0.463955	0.667833	0.534556	0.769309	0.763100	0.875089	0.859397	0.635736	0.471504	...	0.847046	0
INTC	0.585988	0.420854	0.390625	0.816519	0.507251	0.645555	0.458281	0.447049	0.809582	0.738241	...	0.627531	-0
GOOGL	0.315410	0.600025	0.669228	0.912332	0.806847	0.821587	0.715287	0.717756	0.824313	0.780440	...	0.845993	0
TSLA	0.703872	0.253808	0.037233	0.302321	0.248385	-0.092332	-0.277600	-0.251616	0.025575	0.353807	...	-0.117639	-0
UBER	-0.186828	0.326346	0.595928	0.796897	0.661323	0.933308	0.969790	0.937042	0.836565	0.680764	...	0.939538	0
EBAY	0.753732	0.494938	-0.157363	0.434078	0.115591	0.296858	0.087027	0.138580	0.338672	0.644140	...	0.127010	-0
ADBE	0.067604	0.554172	0.816359	0.819614	0.833129	0.863827	0.802739	0.821314	0.783919	0.670509	...	0.913842	0
GTLB	0.310273	0.068856	0.402517	0.690644	0.282373	0.540113	0.404702	0.452625	0.855342	0.460602	...	0.451366	0

25 rows × 25 columns

2.3 Отобразите корреляционную матрицу в виде диаграммы

In [ ]:
```
import matplotlib.pyplot as plt
import seaborn as sns
```

In [ ]:
```
plt.figure(figsize=(15,15))
sns.heatmap(corr, annot=True, cmap='viridis', fmt=".2f")
plt.show()
```

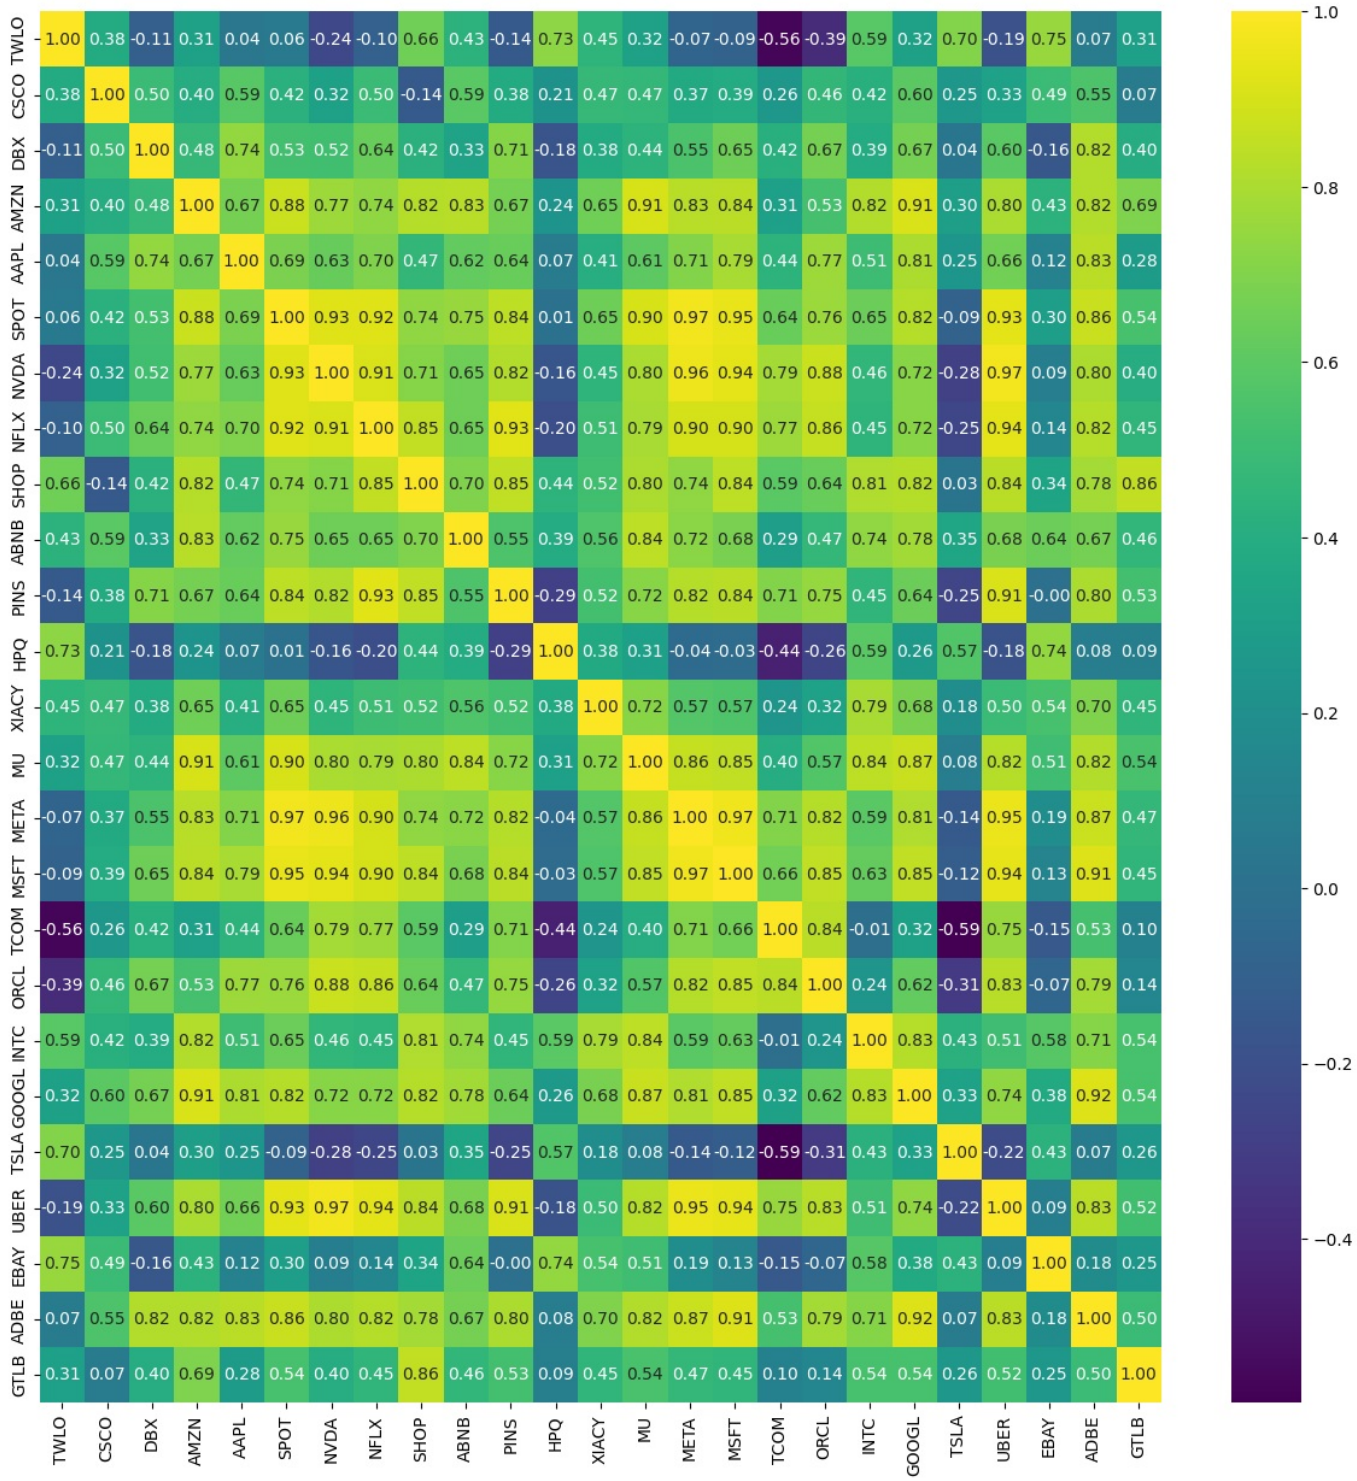

2.4 В соответствии с Вашим вариантом определите:

- акцию с максимальной положительной корреляцией (max)
- акцию с максимальной отрицательной корреляцией (min)
- акцию с минимальной корреляцией (которая больше всего соответствует отсутствию какой-либо корреляции (none))

Вариант 4. Uber (UBER)

In [ ]:
```
# Корелляция акций UBER с другими акциями
uber_corr = corr['UBER']
uber_corr = uber_corr.drop('UBER')
uber_corr
```

Out[ ]:
```
TWLO    -0.186828
CSCO     0.326346
DBX      0.595928
AMZN     0.796897
AAPL     0.661323
SPOT     0.933308
NVDA     0.969790
NFLX     0.937042
SHOP     0.836565
ABNB     0.680764
PINS     0.907751
HPQ     -0.180970
XIACY    0.495835
MU       0.820809
META     0.954444
MSFT     0.939538
TCOM     0.754442
ORCL     0.832075
INTC     0.512572
GOOGL    0.737311
TSLA    -0.221155
EBAY     0.085736
ADBE     0.834611
GTLB     0.521399
Name: UBER, dtype: float64
```

In [ ]:
```
# Акция с максимальной положительная корреляция
max_corr = uber_corr.idxmax()
max_corr
```

Out[ ]:
```
'NVDA'
```

In [ ]:
```
# Акция с максимальной отрицательная корреляция
min_corr = uber_corr.idxmin()
min_corr
```

Out[ ]:
```
'TSLA'
```

In [ ]:
```
# Акция с минимальной корреляцией
none_corr = uber_corr.abs().idxmin()
none_corr
```

Out[ ]:
```
'EBAY'
```

2.5 Постройте диаграммы разброса

- Ваша компания - Компания с min
- Ваша компания - Компания с max
- Ваша компания - Компания с none

In [ ]:
```
# Диаграмма разброса UBER - min corr
plt.scatter(df['UBER'], df[min_corr])
```

Out[ ]:
```
<matplotlib.collections.PathCollection at 0x7aeaac3b6f80>
```

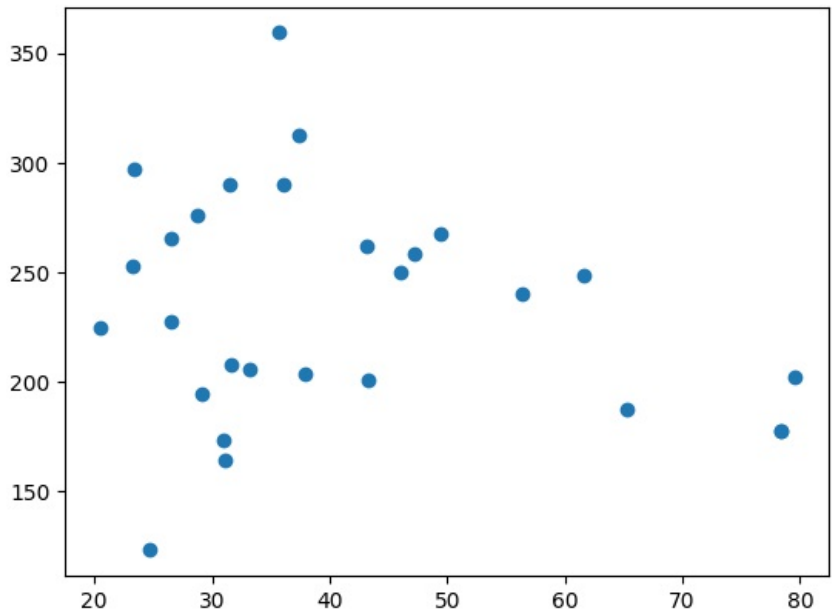

In [ ]:
```
# Диаграмма разброса UBER - max corr
```

```
plt.scatter(df['UBER'], df[max_corr])
```

Out[ ]: <matplotlib.collections.PathCollection at 0x7aeaac4604f0>

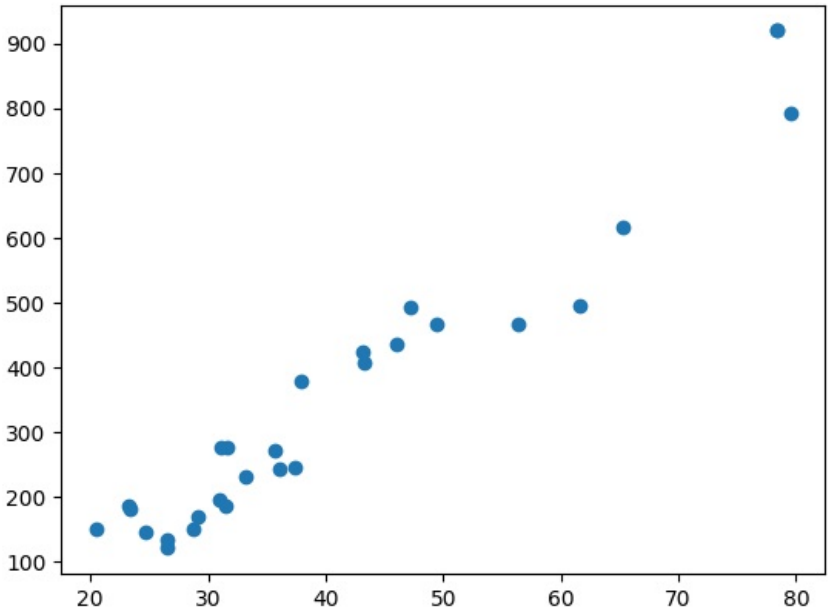

In [ ]:
```
# Диаграмма разброса UBER - none corr
plt.scatter(df['UBER'], df[none_corr])
```

Out[ ]: <matplotlib.collections.PathCollection at 0x7aeaac2d4fa0>

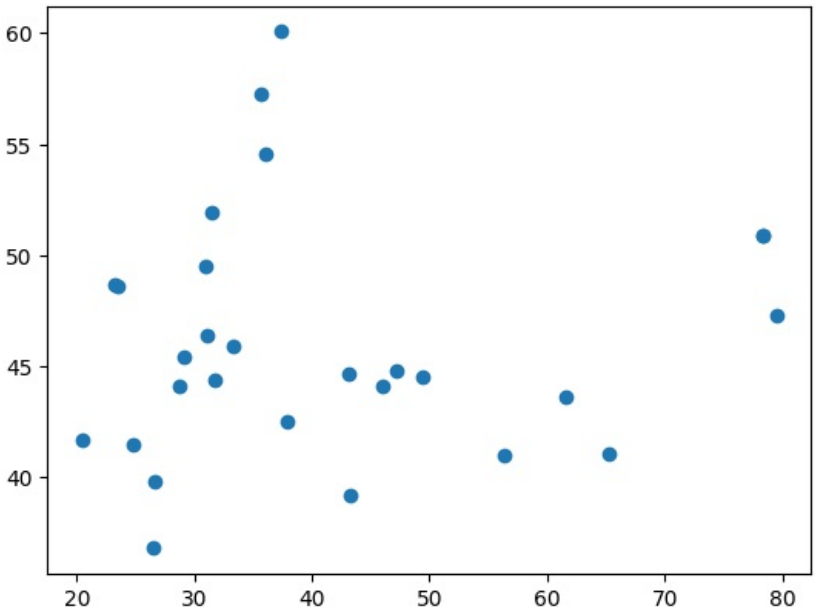

2.6 Рассчитайте среднюю цену акций для каждого месяца (исходные данные взяты с интервалом в месяц)

In [ ]:
```
# Транспонируем исходный датафрейм, чтобы каждый месяц был столбцом, по которому рассчитается среднее
mean = df.T.mean()
mean.name='mean'
mean
```

Out[ ]:
```
Date
2022-01-01    154.857167
2022-02-01    140.774723
2022-03-01    145.272287
2022-04-01    115.763514
2022-05-01    112.316034
2022-06-01     99.256929
2022-07-01    114.014999
2022-08-01    107.380833
2022-09-01     94.437083
2022-10-01     97.227501
2022-11-01    100.671666
2022-12-01     92.028958
2023-01-01    108.279540
2023-02-01    108.613126
2023-03-01    120.210832
2023-04-01    115.778799
2023-05-01    131.258401
2023-06-01    145.426799
2023-07-01    153.207200
2023-08-01    152.016000
2023-09-01    141.760400
2023-10-01    140.454598
2023-11-01    159.367601
2023-12-01    164.859599
2024-01-01    174.886801
2024-02-01    189.609962
2024-03-01    196.083201
2024-03-12    196.083201
Name: mean, dtype: float64
```

2.7 Постройте графики для акций из пункта 4 и средней из пункта 6

In [ ]:
```
df['UBER'].plot(figsize=(17,7), marker='o', color='black', legend=True)
df[max_corr].plot(label=max_corr + ' max', marker='o', color='green', legend=True)
df[min_corr].plot(label=min_corr + ' min', marker='o', color='red', legend=True)
df[none_corr].plot(label=none_corr + ' none', marker='o', color='yellow', legend=True)
mean.plot(marker='o', color='blue', legend=True, grid=True)
```

Out[ ]:
```
<Axes: xlabel='Date'>
```

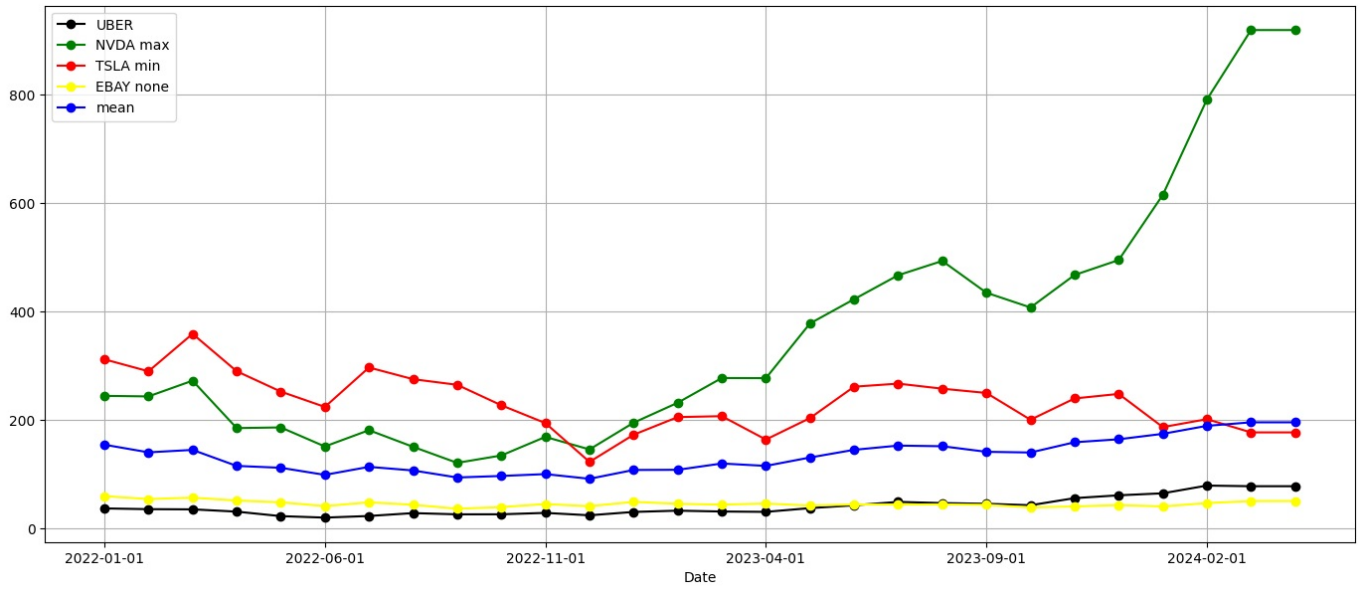

Вывод

В данном домашнее задании были отработаны с использованием языка Python такие навыки и умения, как:

- Решение практических задач по анализу данных
- Загрузка, трансформация, вычисление простых статистик
- Визуализация данных в виде графиков и диаграмм